Sistema de analítica y visualización para el análisis de la participación estudiantil en programas de internacionalización de la Universidad de los Andes

Informe técnico de avance — Semana 9

Fase de datos: comprensión del problema, preparación de datos y análisis exploratorio

Juan David Torres Albarracín
Ingeniería de Sistemas y Computación
Universidad de los Andes

2026

Resumen

Este informe documenta el avance del proyecto de grado hasta la semana 9 del cronograma, correspondiente a las fases de *comprensión del problema*, *comprensión y preparación de datos* y *análisis exploratorio* de la metodología CRISP-DM. El objetivo del proyecto es diseñar, desarrollar y evaluar una herramienta de analítica para la Oficina de Internacionalización que permita explorar la participación estudiantil en programas de movilidad. En esta fase se caracterizaron doce fuentes de datos institucionales anonimizadas, se diagnosticó y corrigió un problema de codificación que afectaba a todas las variables de texto, y se construyó un **pipeline reproducible** que integra las fuentes en un conjunto de datos analítico a nivel estudiante (233 987 estudiantes, 44 variables). La contribución metodológica central de esta fase es la **definición de una señal de participación en internacionalización** derivada de los registros académicos, ya que los datos no contienen una tabla explícita de experiencias de movilidad. El análisis exploratorio sobre el subconjunto de pregrado (140 422 estudiantes, tasa de participación del 4,15 %) revela una tendencia temporal con una caída atribuible a la pandemia y recuperación posterior, fuerte heterogeneidad por facultad y programa, un gradiente socioeconómico y asociaciones consistentes entre participación y desempeño académico. Sobre esta base, y en acuerdo con la dirección del proyecto, el alcance se reorientó hacia un producto **descriptivo y exploratorio**: se diseñó e implementó un **dashboard web interactivo** (React, arquitectura sin

servidor sobre un cubo de datos pre-agregado) que permite filtrar la participación por múltiples dimensiones —filtros categóricos y *sliders* de rango para las variables numéricas— y visualizarla con gráficos interactivos, incluyendo comparaciones entre estudiantes con y sin internacionalización. Queda fuera del alcance la construcción de modelos predictivos.

Índice

1. Introducción y objetivo **3**

2. Comprensión del problema (Semana 4) **3**

2.1. Usuarios y preguntas analíticas 3

2.2. Alcance y criterios de éxito de la fase 4

3. Comprensión y calidad de los datos (Semanas 5–6) **4**

3.1. Inventario de fuentes 4

3.2. Calidad de datos y codificación 5

4. Preparación de datos (Semanas 7–8) **5**

4.1. Definición de la señal de internacionalización 5

4.2. Construcción del dataset analítico 7

4.3. Tasa de participación por nivel 7

4.4. Tratamiento de valores faltantes 7

5. Análisis exploratorio (Semanas 8–9) **7**

5.1. Panorama univariado 7

5.2. PA1 — Evolución temporal 9

5.3. PA3 — Modalidades en el tiempo 9

5.4. PA2 — Participación por facultad y programa 10

5.5. PA4 — Momento de la trayectoria 11

5.6. PA5–PA6 — Perfil académico y diferencias entre grupos 11

5.7. Asociación multivariada 13

5.8. Indicadores principales 13

6. Hallazgos e insights principales **14**

7. Reorientación del alcance: foco descriptivo **16**

8. Diseño e implementación del dashboard **17**

8.1. Arquitectura 17

8.2. Dimensiones de filtrado 17

8.3. Componentes de visualización 18
8.4. Reproducibilidad del dashboard 19

9. Trazabilidad de decisiones metodológicas 19

10. Consideraciones de privacidad 21

11. Limitaciones 21

12. Trabajo pendiente (semanas 10–17) 21

13. Conclusiones 22

1. Introducción y objetivo

El proyecto propone una herramienta de analítica y visualización para que la Oficina de Internacionalización de la Universidad de los Andes pueda explorar la participación estudiantil en programas de movilidad e internacionalización, y disponer de información útil para la toma de decisiones. El desarrollo sigue la metodología CRISP-DM [1, 2] combinada con prácticas iterativas de desarrollo de software.

Este documento es el informe técnico principal del proyecto y recoge, de manera progresiva, el trabajo realizado hasta la **semana 9** del cronograma. Las semanas 4 a 9 corresponden a las tres primeras fases de CRISP-DM:

1. **Comprensión del problema** (semana 4): usuarios, preguntas analíticas, alcance y criterios de éxito.
2. **Comprensión y calidad de datos** (semanas 5–6): inventario de fuentes, diccionario de datos y evaluación de calidad.
3. **Preparación de datos y análisis exploratorio** (semanas 7–9): pipeline de integración, definición de la señal de internacionalización, construcción del dataset analítico y EDA.

El trabajo es reproducible: el código fuente del pipeline está en el paquete `src/`, los análisis en los notebooks `notebooks/01–05`, y las figuras y tablas de este informe se generan automáticamente en `reports/`. La trazabilidad de las decisiones metodológicas se concentra en este documento (Sección 9).

2. Comprensión del problema (Semana 4)

2.1. Usuarios y preguntas analíticas

Se identificaron tres perfiles de usuario: analistas de la Oficina (consulta y reporte de indicadores), coordinación/dirección (planeación y comparación entre unidades) y el equipo técnico de mantenimiento. A partir de la propuesta se priorizaron siete preguntas analíticas (PA):

PA1 Evolución temporal de la participación.

PA2 Participación por facultad y programa académico.

PA3 Modalidades de movilidad más frecuentes.

PA4 Momento de la trayectoria académica en que ocurre la movilidad.

PA5 Características académicas asociadas a la participación.

PA6 Diferencias entre grupos (género, estrato, tipo de admisión).

PA7 Perfilamiento descriptivo: ¿qué características distinguen a los estudiantes que participan de los que no? (sin modelos predictivos).

2.2. Alcance y criterios de éxito de la fase

El alcance de la fase de datos comprende: un dataset analítico documentado y reproducible, la definición justificada de la señal de internacionalización, un informe de calidad de datos y un EDA que responda PA1–PA6. Este EDA es, además, el insumo directo del dashboard descriptivo descrito en la Sección 8. El detalle de requerimientos funcionales y no funcionales se encuentra en `docs/01_requerimientos_semana4.md`.

3. Comprensión y calidad de los datos (Semanas 5–6)

3.1. Inventario de fuentes

Se dispone de doce archivos `parquet` anonimizados. La Tabla 1 resume las fuentes núcleo utilizadas en esta fase, su tamaño y granularidad. Todas identifican al estudiante mediante un código anonimizado; dos fuentes grandes usan el sufijo `_ANOM`, lo que se normaliza en el pipeline.

Cuadro 1: Fuentes núcleo del proyecto y su granularidad.

Fuente	Filas	Variables	Unidad de información
informacion_actual	233 987	73	Estudiante (snapshot, 1 fila/estudiante)
historial_materias	6 958 732	14	Curso–estudiante–periodo
programas	1 770 486	18	Programa–estudiante–periodo
historial_rendimiento	1 230 195	28	Estudiante–periodo
percentiles_historicos	994 875	18	Estudiante–periodo
icfes_saber11	262 148	10	Presentación de examen
grados	139 429	10	Grado obtenido
historial_opciones	173 387	14	Opción–estudiante–periodo
examenes_clasificacion	79 599	8	Clasificación por estudiante
capp_creditos	30 771	7	Cálculo de créditos

Decisión (unidad de análisis). Se adopta el *estudiante* como unidad de análisis y `informacion_actual` (una fila por estudiante) como columna vertebral; las fuentes tran-

saccionales se agregan a nivel estudiante. El diccionario de datos completo se exporta en `reports/tables/diccionario_datos.csv`.

3.2. Calidad de datos y codificación

El perfilamiento (notebook `02`) identificó cuatro problemas de calidad y las decisiones correspondientes:

1. Codificación (*mojibake*). Todas las columnas de texto presentaban caracteres corruptos. Se diagnosticaron **dos esquemas distintos**: en `informacion_actual` el texto UTF-8 fue interpretado con CP437 (p. ej. *Magíster* aparecía como `Mag`+símbolo y *Opción* con un símbolo en lugar de la "ó"); en `historial_materias` fue interpretado con CP850 (p. ej. *DOBLE TITULACIÓN* y *PRÁCTICA* con símbolos de caja en lugar de las vocales acentuadas). Se implementó una corrección automática que detecta el esquema aplicable y recupera el texto en español (*Magíster*, *Opción*, *DOBLE TITULACIÓN*, *PRÁCTICA*). **Esta corrección es imprescindible**: sin ella, categorías idénticas se contarían como distintas.

2. Valores faltantes. Variables socioeconómicas y de ingreso presentan ausencias elevadas, en parte por la heterogeneidad del snapshot (estudiantes antiguos sin ICFES moderno, trayectorias cortas sin rendimiento consolidado). No se descartan a priori; se evalúa su cobertura en el subconjunto de pregrado (Sección 4.4).

3. Múltiples filas por estudiante en ICFES, CAPP y exámenes. Se adopta una regla de deduplicación explícita: para ICFES, el registro de mayor puntaje total; para CAPP y exámenes, el más reciente por fecha.

4. Valores atípicos. El PGA se encuentra dentro del rango esperado $[0, 5]$; los valores bajos (incluidos ceros) corresponden a inicios de trayectoria y se conservan.

El informe de calidad completo está en `reports/tables/informe_calidad_datos.csv`.

4. Preparación de datos (Semanas 7–8)

4.1. Definición de la señal de internacionalización

Las fuentes entregadas **no contienen una tabla explícita de experiencias de internacionalización**. Por lo tanto, la participación debe *derivarse* de los registros académicos. Esta es la decisión metodológica central de la fase de datos.

Criterio adoptado. La Universidad inscribe las experiencias de movilidad como asignaturas en la historia académica del estudiante (`historial_materias`). Se marca un registro como *evento de movilidad* cuando el nombre del curso (corregido de encoding) coincide con un patrón de movilidad — `INTERCAMBIO`, `VIAJE INTERNACIONAL`, `SEMANA INTERNACIONAL`, `DOBLE TITULAC` — o cuando su código pertenece a una lista canónica de cursos de movilidad (p. ej. `DECA-2201`, `INTL-2201`, `MBAE-4543`). Cada evento se clasifica en una *modalidad*.

Justificación. (i) Se usa el nombre del curso *además* del código porque una misma experiencia aparece bajo múltiples códigos de departamento; confiar solo en códigos subestimaría la señal. (ii) Se excluye la modalidad "intercambio nacional" del foco internacional mediante un parámetro explícito. (iii) La señal se construye de forma auditable y trazable. La definición está implementada en `src/internationalization.py`.

La Tabla 2 y la Figura 1 resumen la composición de la señal.

Cuadro 2: Composición de la señal de internacionalización por modalidad (eventos).

Modalidad	**Eventos**
Intercambio internacional	7 726
Doble titulación	817
Viaje internacional de estudio	559
Semana internacional	396
Intercambio virtual	28
Total	**9 526**

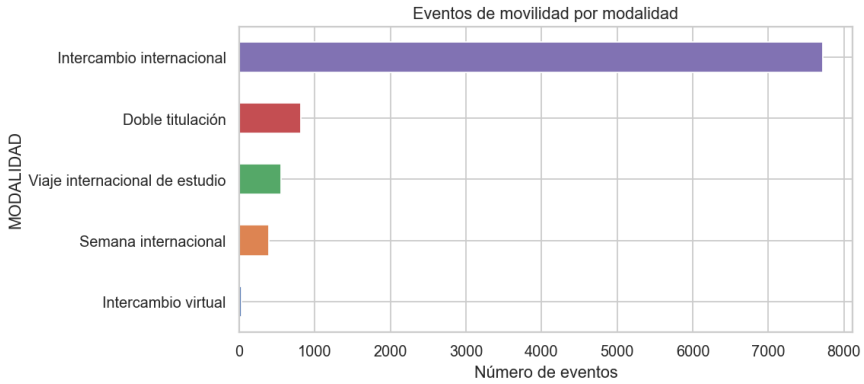


Figura 1: Eventos de movilidad por modalidad. El intercambio internacional concentra cerca del 81 % de los eventos.

4.2. Construcción del dataset analítico

El pipeline (`src/build_dataset.py`, ejecutable con `python -m src.build_dataset`) integra las fuentes mediante uniones por la izquierda sobre la columna vertebral, de modo que no se pierden estudiantes del universo. Agrega el desempeño académico (PGA histórico y último, créditos, semestres), la posición relativa (percentil de PGA), el avance (semestre), las pruebas de ingreso (ICFES), la clasificación de inglés/matemáticas, el progreso de créditos (CAPP) y la etiqueta `PARTICIPA`. El resultado es un dataset de 233 987 **estudiantes** × 44 **variables**, validado automáticamente (clave única, conservación del universo, etiqueta binaria).

Fecha del primer evento. El pipeline conserva, por estudiante, el primer periodo de movilidad (`PRIMER_PERIODO_MOVILIDAD`), que habilita el análisis temporal del dashboard (año en que ocurre la primera experiencia).

4.3. Tasa de participación por nivel

La participación es un fenómeno minoritario: 3,43 % **global** y 4,15 % **en pregrado**. El pregrado concentra el mayor volumen de participantes (5 821) y la tasa más alta entre los niveles con volumen relevante, lo que motiva centrar el análisis en este nivel.

4.4. Tratamiento de valores faltantes

En el subconjunto de pregrado, la cobertura de las variables candidatas es: `NIVEL_INGLES` $\approx$ 12 % (faltante 87,8 %), bloque de PGA/percentil/avance $\approx$ 45–55 % de faltante, e ICFES $\approx$ 45 % de faltante. Decisiones:

- `NIVEL_INGLES` se **descarta** como variable principal por cobertura insuficiente; se conserva el puntaje de inglés del ICFES.
- No se imputa: el EDA y el dashboard trabajan sobre los datos observados. Los faltantes se preservan como una categoría explícita "Sin dato" en los filtros y agregaciones, haciendo visible su magnitud en lugar de ocultarla, en línea con la literatura sobre datos faltantes [3].

5. Análisis exploratorio (Semanas 8–9)

5.1. Panorama univariado

La Figura 2 muestra la distribución de variables categóricas en pregrado. La población se concentra en pocas facultades grandes (Ingeniería es la de mayor volumen), con género relativamente equilibrado y fuerte presencia de estratos 3–6; una fracción no despreciable

tiene estrato ausente. La Figura 3 confirma escalas coherentes: PGA concentrado en 3,8–4,0, percentil aproximadamente uniforme e ICFES aproximadamente simétrico alrededor de ~ 355.

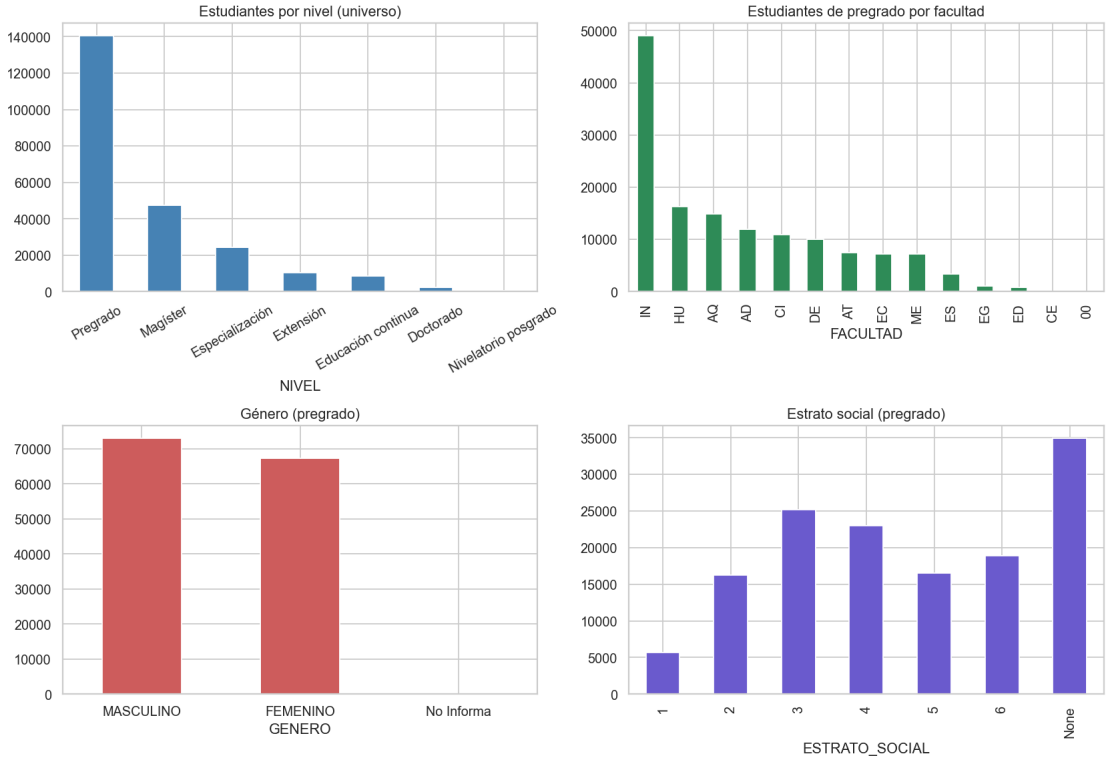


Figura 2: Distribuciones univariadas de variables categóricas (pregrado).

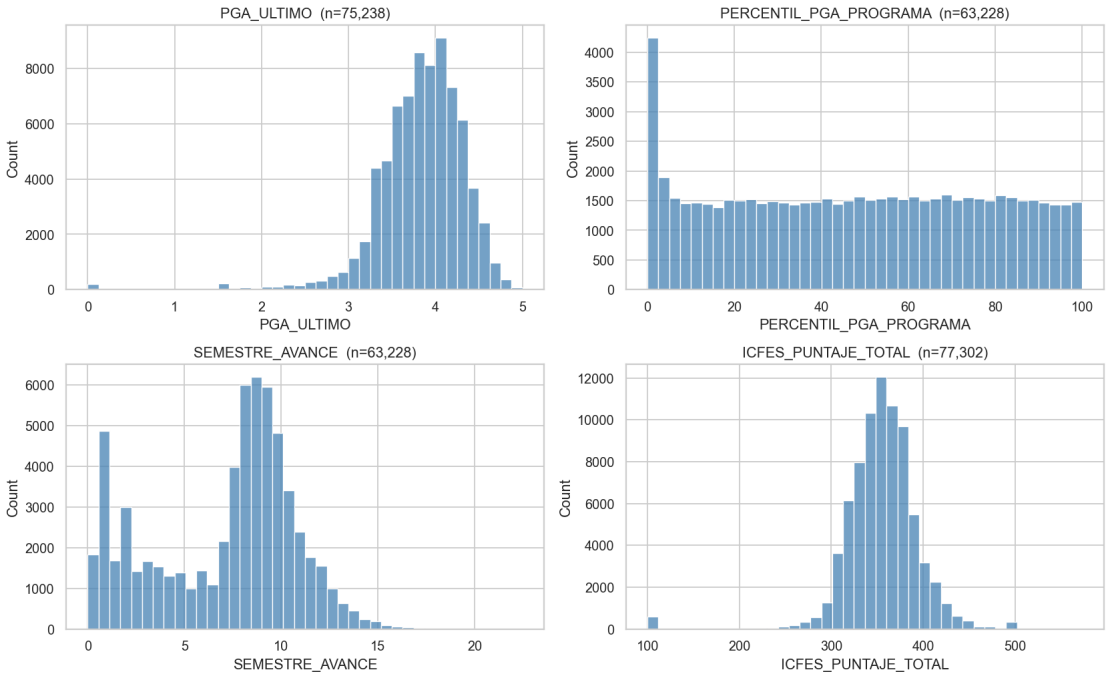


Figura 3: Distribuciones univariadas de variables numéricas de desempeño e ingreso (pregrado).

5.2. PA1 — Evolución temporal

La Figura 4 muestra una tendencia creciente de la movilidad hasta estabilizarse en $\sim$ 400–450 eventos anuales en la década de 2010, una **caída pronunciada en 2020–2021** (447 eventos en 2019 frente a 257 y 268 en 2020 y 2021) atribuible a las restricciones de la pandemia de COVID-19, y una **recuperación fuerte desde 2022** que alcanza máximos históricos ($\sim$ 585–595 eventos en 2023–2025). Que la señal reaccione a un choque externo conocido de la forma esperada es también una validación indirecta de su correcta construcción.

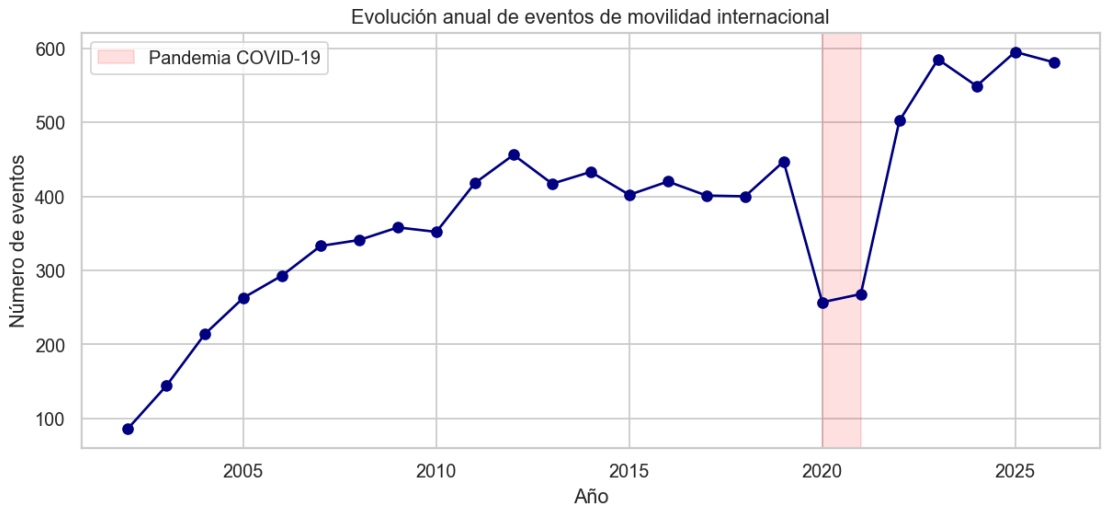


Figura 4: Evolución anual de eventos de movilidad internacional. La franja roja señala el periodo de pandemia.

5.3. PA3 — Modalidades en el tiempo

La Figura 5 muestra que el intercambio internacional domina en todo el periodo, con contribuciones menores pero estables de doble titulación, viajes y semanas internacionales. El intercambio virtual aparece puntualmente alrededor de 2020–2021, coherente con la sustitución de la movilidad física durante la pandemia.

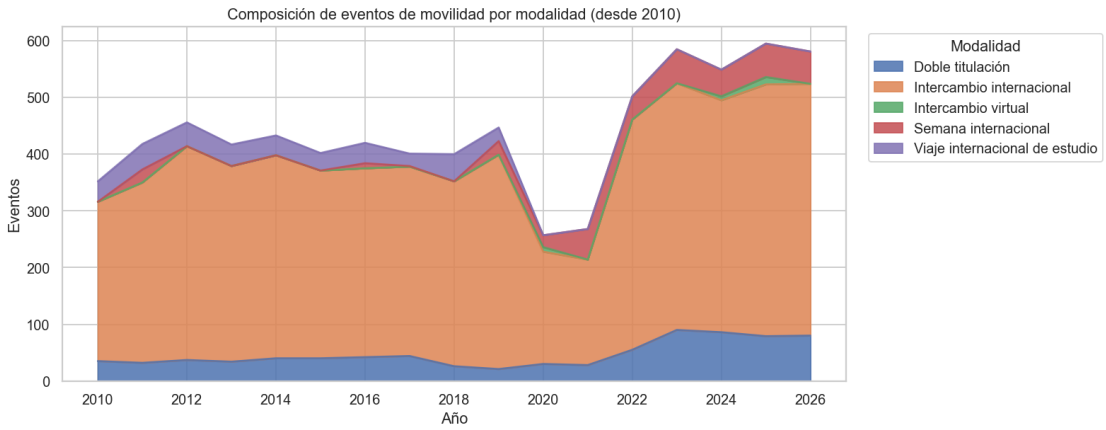


Figura 5: Composición de eventos de movilidad por modalidad desde 2010.

5.4. PA2 — Participación por facultad y programa

La participación es muy heterogénea entre unidades académicas (Figura 6): la tasa va desde $\sim 0{,}1\,\%$ hasta $\sim 12{,}3\,\%$ (Administración presenta la tasa más alta; Arquitectura, Economía y Derecho también destacan). A nivel de programa (Figura 7) la heterogeneidad es aún mayor. La facultad/programa es, por tanto, una variable estructural clave y una dimensión de segmentación prioritaria para el dashboard.



Figura 6: Tasa de participación por facultad (pregrado).

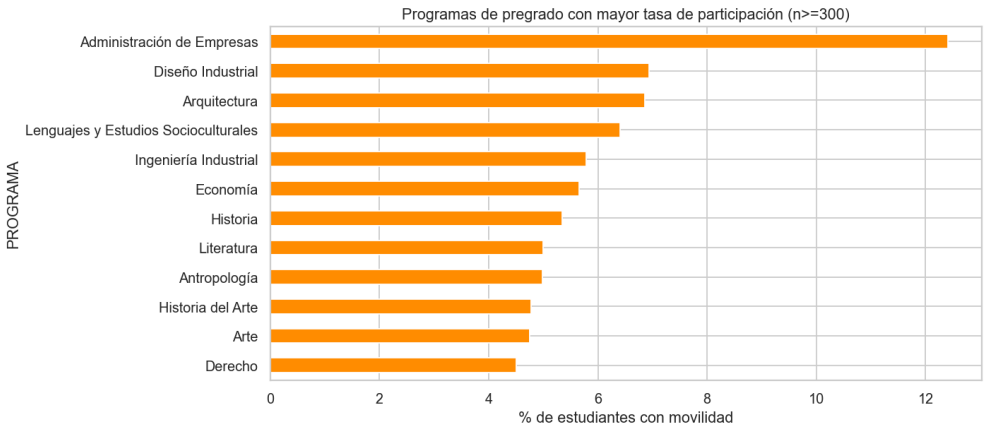


Figura 7: Programas de pregrado con mayor tasa de participación ($n \geq 300$).

5.5. PA4 — Momento de la trayectoria

Los participantes se concentran en etapas intermedias y avanzadas de la carrera (Figura 8): su avance mediano es de $\sim$ 8,75 semestres frente a $\sim$ 8 en no participantes, con una distribución mucho más estrecha. Esto es consistente con que la movilidad suele requerir haber cursado un mínimo de créditos, y motiva el filtro por semestre de avance en el dashboard.

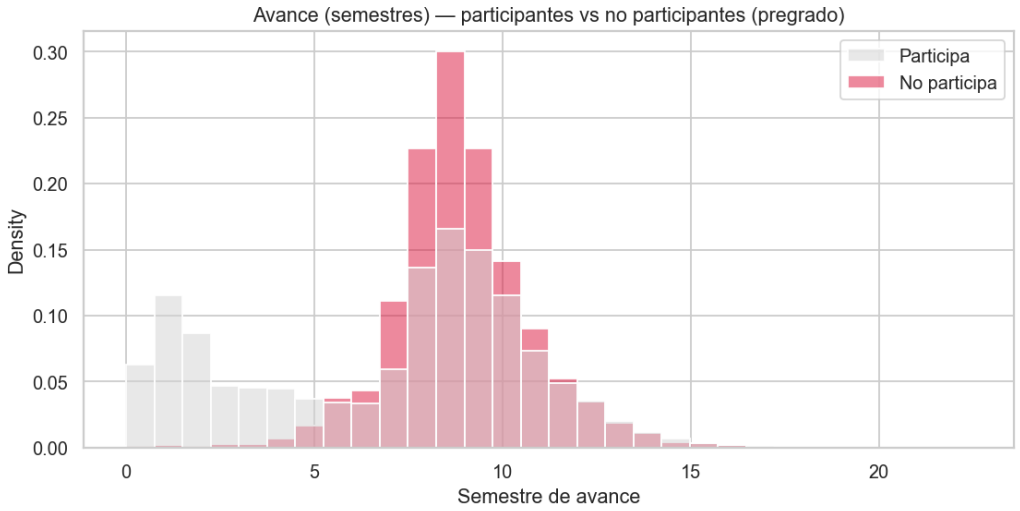


Figura 8: Avance en semestres: participantes frente a no participantes (pregrado).

5.6. PA5–PA6 — Perfil académico y diferencias entre grupos

Los participantes muestran, en promedio, mejor desempeño y mejor perfil de ingreso (Figura 9, Tabla 3). Existe además un **gradiente socioeconómico** claro (Tabla 4): la tasa de participación crece de forma monótona con el estrato (de $\sim 0{,}4\,\%$ en estratos 1–2 a $\sim 9{,}5\,\%$ en estrato 6) y es algo mayor en mujeres. Estos resultados deben interpretarse como **asociaciones, no causas**, y comunicarse como análisis de equidad.

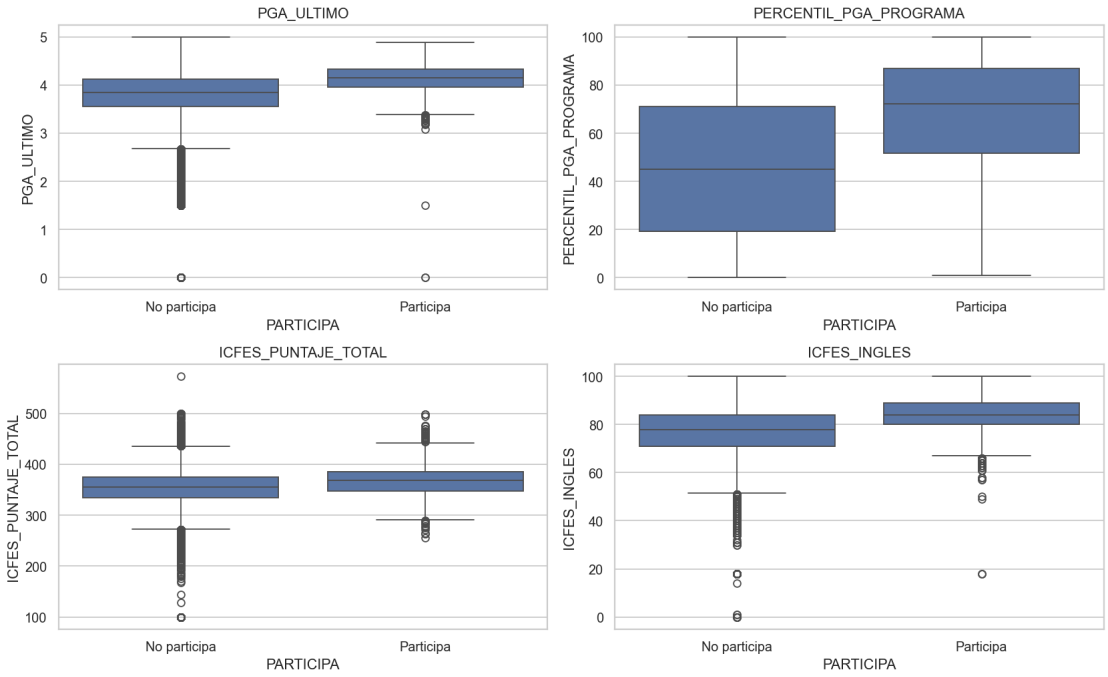


Figura 9: Comparación del desempeño y perfil de ingreso entre participantes y no participantes (pregrado).

Cuadro 3: Perfil promedio de participantes y no participantes (pregrado).

Variable	**No participa**	**Participa**	**Diferencia**
PGA (último)	3,81	4,14	+0,33
Percentil PGA (programa)	45,8	67,7	+21,9
Semestre de avance	6,93	8,87	+1,95
ICFES total	354,3	368,4	+14,1
ICFES inglés	77,4	84,6	+7,2
% créditos aprobados	0,86	0,94	+0,09

Cuadro 4: Tasa de participación por grupo (pregrado).

Estrato social		**Género**	
Estrato	**Tasa (%)**	**Género**	**Tasa (%)**
6	9,48	Femenino	4,65
5	6,26	Masculino	3,68
4	3,33		
3	0,94		
2	0,43		
1	0,42		

5.7. Asociación multivariada

La Figura 10 presenta las correlaciones entre variables numéricas y la participación. Individualmente, las correlaciones con `PARTICIPA` son de magnitud baja a moderada (lo esperable para un evento poco frecuente), pero con signos coherentes: el percentil de PGA por programa y el PGA muestran la asociación positiva más clara, seguidos del avance y el perfil de ingreso. Ninguna variable domina por sí sola: la participación es un fenómeno multidimensional, lo que justifica un tablero que permita cruzar varias dimensiones a la vez en lugar de quedarse en indicadores aislados. Las correlaciones entre variables de desempeño (p. ej. PGA y percentil) indican que varias de ellas aportan información redundante, algo a tener en cuenta al leer los filtros del dashboard.

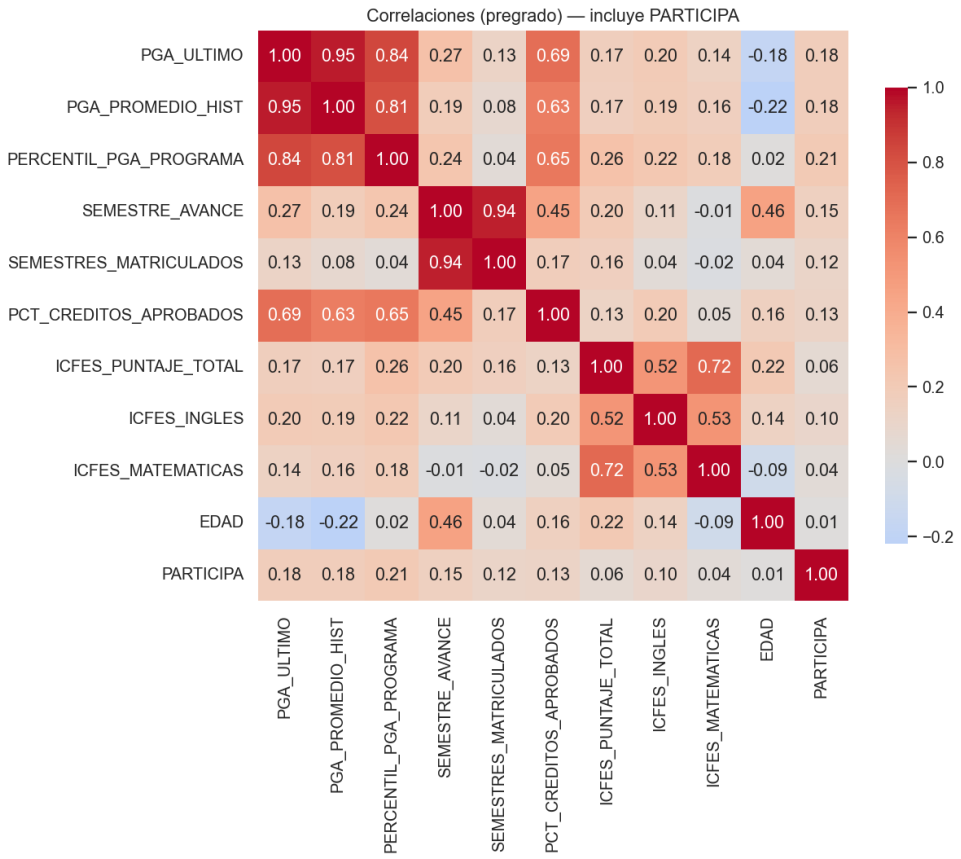


Figura 10: Matriz de correlaciones de variables numéricas (pregrado), incluyendo la etiqueta de participación.

5.8. Indicadores principales

La Tabla 5 consolida los indicadores que alimentarán el módulo de resumen del dashboard (exportados en `reports/tables/indicadores_principales.csv`).

Cuadro 5: Indicadores principales de la fase de datos.

Indicador	**Valor**
Estudiantes (universo)	233 987
Estudiantes de pregrado	140 422
Participantes (total)	8 036
Participantes (pregrado)	5 821
Tasa de participación global	3,43 %
Tasa de participación en pregrado	4,15 %
Eventos de movilidad	9 526
Año pico de eventos	2025
Modalidad principal	Intercambio internacional
Facultad con mayor tasa	Administración
Avance mediano de participantes	8,75 semestres

6. Hallazgos e insights principales

Esta sección sintetiza los resultados del análisis exploratorio en hallazgos accionables para la Oficina de Internacionalización. Todas las cifras provienen del dataset analítico y son reproducibles con el pipeline; salvo indicación contraria, se refieren al subconjunto de **pregrado** (140 422 estudiantes), foco del proyecto. Se reitera la advertencia metodológica: las relaciones reportadas son *asociaciones* observadas en los datos, no relaciones causales.

Insight 1 — La participación es minoritaria y muy concentrada

Solo el 4,15 % de los estudiantes de pregrado registra alguna experiencia de internacionalización. Además, la participación está **fuertemente concentrada**: las tres facultades con más participantes —Ingeniería, Administración y Arquitectura y Diseño— reúnen el 66 % de todos los participantes de pregrado, y las cinco primeras, el 84 %. *Implicación:* las estrategias de promoción pueden segmentarse por unidad académica, y existe un amplio margen de crecimiento en las facultades hoy subrepresentadas.

Insight 2 — Volumen y propensión no coinciden

Conviene distinguir dos lecturas. **Ingeniería** aporta el mayor *número* de participantes (1 529) pero con una tasa baja (3,1 %), porque es una facultad muy grande. **Administración**, en cambio, tiene la *tasa* más alta (12,3 %): proporcionalmente, es la facultad donde la movilidad está más instalada en la cultura del programa. La brecha entre la facultad de mayor y menor tasa (entre las grandes) supera un orden de magnitud. *Implicación:*

el dashboard permite alternar entre "número" y "tasa" precisamente para no confundir tamaño con propensión al diseñar intervenciones.

Insight 3 — Existe un marcado gradiente socioeconómico

La tasa de participación crece de forma monótona con el estrato: pasa de $\sim 0{,}4\,\%$ en estratos 1–2 a 9,5 % en estrato 6. Un estudiante de estrato 6 participa cerca de **22 veces más** que uno de estrato 1–2. Este es el hallazgo de equidad más relevante del análisis: sugiere que el costo y las condiciones de la movilidad internacional podrían estar actuando como barrera para los estratos más bajos. *Implicación:* es un insumo directo para políticas de becas o apoyos focalizados; debe comunicarse como una brecha a atender, nunca como un criterio de selección.

Insight 4 — Brecha de género moderada pero consistente

Las mujeres participan más que los hombres (4,7 % frente a 3,7 %) y representan el 54 % de los participantes de pregrado. La diferencia es menor que la socioeconómica, pero estable.

Insight 5 — La movilidad ocurre en etapas avanzadas de la carrera

El 89 % de los participantes tiene siete o más semestres de avance al momento de su primera experiencia (avance mediano 8,8 semestres, frente a 8,0 en no participantes, con una distribución mucho más concentrada). La movilidad es, típicamente, una decisión de segunda mitad de carrera. *Implicación:* las campañas de información son más pertinentes dirigidas a estudiantes de semestres intermedios, antes de esa ventana.

Insight 6 — Perfil académico más alto entre participantes

Los participantes tienden a tener mejor desempeño: su PGA mediano es 4,2 (vs. 3,8) y, sobre todo, el 77 % se ubica por encima de la mediana de su programa en percentil de PGA (y el 46 %, por encima del percentil 75). También ingresaron con mejores puntajes (ICFES total e inglés). *Implicación:* el buen desempeño se asocia con mayor participación; queda abierto para la Oficina indagar si esto refleja requisitos académicos de los programas de movilidad o autoselección de los estudiantes.

Insight 7 — El intercambio domina, pero hay diversidad de formatos

El 81 % de los eventos son intercambios internacionales; les siguen la doble titulación (8,6 %), el viaje internacional de estudio (5,9 %) y la semana internacional (4,2 %). El

intercambio virtual es marginal (0,3 %) y aparece casi exclusivamente alrededor de 2020–2021. La movilidad recurrente existe pero es poco frecuente: solo el 12,7 % de los participantes registra más de una experiencia.

Insight 8 — Choque de la pandemia y recuperación con rebote

La movilidad promedió ~ 414 eventos anuales entre 2015 y 2019, cayó un 43 % en 2020 y promedió apenas ~ 262 en 2020–2021, para recuperarse con fuerza desde 2022 (~ 558 anuales en 2022–2025) y superar en ~ 31 % el nivel prepandemia hacia 2023. *Implicación:* la demanda de movilidad no solo se recuperó sino que creció, lo que es relevante para la planeación de capacidad de la Oficina.

Síntesis

En conjunto, el perfil típico del participante de pregrado es un estudiante de estrato alto, en la segunda mitad de la carrera, con desempeño por encima de la mediana de su programa, que realiza un intercambio internacional. Los dos frentes con mayor potencial de política son la **equidad socioeconómica** (reducir la brecha por estrato) y la **ampliación hacia facultades de baja propensión**. Estos hallazgos son explorables de forma interactiva en el dashboard (Sección 8).

7. Reorientación del alcance: foco descriptivo

Tras el análisis exploratorio y en acuerdo con la dirección del proyecto, se decidió **reorientar el alcance hacia un producto descriptivo y exploratorio**, dejando fuera del alcance la construcción de modelos predictivos. El objetivo pasa a ser una herramienta que permita a la Oficina de Internacionalización *explorar y visualizar* la participación con el mayor grado de interactividad y granularidad de filtrado posible.

Justificación de la decisión. (i) El valor principal para la Oficina está en responder de forma autónoma las preguntas PA1–PA6 (quiénes, cuándo, dónde y en qué modalidad participan los estudiantes), que son descriptivas. (ii) Un modelo predictivo introduce riesgos de interpretación (confundir asociación con causa) y de uso indebido sobre estudiantes individuales, en tensión con el principio de no presentar decisiones automáticas y con la minimización de datos. (iii) La tasa de participación baja (~ 4 %) hace que un clasificador aporte poco valor accionable frente a un buen tablero descriptivo. En consecuencia, la pregunta PA7 se reformula como una pregunta *descriptiva* de perfilamiento — ¿qué características distinguen a los participantes? — ya respondida en la Sección 5.6 mediante comparación de grupos, sin necesidad de un modelo. El trabajo de datos de las semanas 4–9 (señal, dataset, EDA) sigue siendo el insumo directo del tablero.

8. Diseño e implementación del dashboard

El producto central es un **dashboard web interactivo** que materializa el principio de exploración de Shneiderman —visión general primero, luego zoom y filtro, y detalle bajo demanda— [4], con un diseño orientado a las tareas del usuario y no a la estructura interna de los datos [5].

8.1. Arquitectura

Se adoptó una arquitectura **sin servidor** (*client-side*) compuesta por dos piezas:

1. **Capa de datos (Python).** El módulo `src/export_dashboard.py` transforma el dataset analítico en un **cubo pre-agregado** y lo exporta como un único archivo JSON (`dashboard/public/data.json`). Cada fila del cubo es una combinación única de dimensiones y lleva el número de estudiantes y de participantes. El cubo combina **nueve dimensiones categóricas** con **cuatro dimensiones numéricas discretizadas** (PGA, semestre de avance, puntaje ICFES y edad), estas últimas guardadas como enteros en una rejilla fina (p. ej. PGA en pasos de 0,25) para habilitar *sliders* de rango sin perder la capacidad de *cross-filtering* exacto. El cubo resultante tiene 85 221 celdas y pesa 3,5 MB, que se reducen a $\sim$ 0,34 MB al comprimir con gzip (muy ligero en la transferencia).
2. **Capa de presentación (React + Vite).** Una aplicación de página única construida con React y la biblioteca de gráficos *Recharts*, elegida por su bajo peso e interactividad nativa (*hover*, *tooltips*). El *bundle* de producción pesa $\sim$ 169 KB comprimido, acorde con el requisito de una herramienta ligera. El navegador recalcula todos los indicadores sumando las celdas del cubo que satisfacen los filtros activos.

Decisión clave (cubo agregado vs. microdatos). En lugar de enviar los 233 987 registros individuales al navegador, se envía el cubo agregado. Esto (i) mantiene la aplicación ligera, (ii) permite filtrar por *cualquier* combinación de dimensiones del lado del cliente, sin latencia de red, y (iii) respeta el principio de minimización: **no se exponen registros individuales**, solo conteos agregados, en coherencia con la Ley 1581 de 2012 [6, 7].

8.2. Dimensiones de filtrado

El tablero expone dos tipos de filtros con *cross-filtering* en vivo:

- **Ocho filtros categóricos de selección múltiple**: nivel académico, facultad, programa, género, estrato social, tipo de admisión, estado académico y modalidad de movilidad. Junto a cada opción se muestra un conteo contextual que, por decisión de diseño, indica el número de estudiantes **con experiencia de internacionalización** (partici-

pantes) —no el total— bajo el resto de filtros activos, de modo que el usuario vea de inmediato dónde se concentra la movilidad.

- **Cuatro *sliders* de rango** para las variables numéricas (PGA, semestre de avance, puntaje ICFES y edad). Cada *slider* tiene doble manija y, además, **campos de entrada manual en ambos extremos**: el usuario puede escribir un valor exacto, que se valida contra el rango real de la variable y se ajusta al paso de la rejilla. Un control adicional permite incluir o excluir a los estudiantes sin dato en esa variable.

Cualquier combinación de filtros recalcula instantáneamente los indicadores y gráficos.

8.3. Componentes de visualización

El tablero se organiza alrededor de las preguntas analíticas (Tabla 6), agrupadas en cuatro bloques: indicadores (KPI), *participantes vs. no participantes*, *distribuciones numéricas* y *rankings por categoría*. Mejoras de legibilidad e interactividad:

- Cada barra muestra su valor **siempre visible** como etiqueta, no solo al pasar el mouse.
- Cada gráfico de ranking exhibe una etiqueta de **Total** (suma de todas las categorías), como anotación y no como una barra adicional.
- Los gráficos de ranking permiten alternar la métrica entre número de estudiantes, número de participantes y tasa (%).
- Las comparaciones *participantes vs. no participantes* muestran, para cada categoría, qué porcentaje de cada grupo cae en ella, revelando en qué se diferencian ambos grupos.
- Las distribuciones numéricas combinan barras (número de estudiantes) con una línea de tasa de participación en doble eje.
- Se conservan los *tooltips* de *hover* con el detalle, y el clic sobre una barra de facultad o programa aplica el filtro correspondiente.

Cuadro 6: Módulos del dashboard y preguntas analíticas que responden.

Componente	**Qué muestra**	**PA**
Indicadores (KPI)	Estudiantes de la selección, participantes, tasa y eventos.	—
Serie temporal	Movilidad por año (con franja de pandemia).	PA1
Donut de composición	Participantes vs. no participantes en la selección.	PA5
Perfil comparado (estrato, facultad, tipo de admisión)	% de cada grupo (participa / no participa) por categoría.	PA5–PA6
Distribución de PGA / avance / ICFES / edad	Barras (estudiantes) + línea de tasa, doble eje.	PA4–PA6
Ranking por facultad	Participación por facultad; clic para filtrar.	PA2
Ranking por programa	Top programas de la selección; clic para filtrar.	PA2
Modalidades	Composición por tipo de experiencia.	PA3
Modalidades en el tiempo	Área apilada por modalidad desde 2010.	PA3
Ranking por tipo de admisión / género / nivel	Participación por esas dimensiones.	PA6

8.4. Reproducibilidad del dashboard

El tablero se regenera de forma reproducible: `python -m src.export_dashboard` reconstruye el cubo a partir del dataset analítico, y `npm run build` dentro de `dashboard/` produce la versión estática desplegable. Como validación, se verificó que los indicadores calculados en el navegador coinciden con los del pipeline: 233 987 estudiantes y tasa global 3,43 %; al filtrar pregrado, 140 422 estudiantes y 4,15 %; pregrado con estrato 6, 9,48 %. También se comprobaron los *sliders*: al restringir el PGA a $\geq 4{,}5$ la tasa de participación sube a 7,3 %, y el cruce de pregrado con ICFES ≥ 400 da 5,3 %, ambos coherentes con las asociaciones del análisis exploratorio.

9. Trazabilidad de decisiones metodológicas

La Tabla 7 consolida las decisiones relevantes de la fase, su justificación y su ubicación en el repositorio.

Cuadro 7: Trazabilidad de decisiones metodológicas (semanas 4–9).

Decisión	**Justificación**	**Dónde**
Unidad de análisis = estudiante	`informacion_actual` tiene 1 fila/estudiante; permite integrar el resto por agregación.	nb 01, `build_dataset`
Corrección automática de dos esquemas de *mojibake*	Evita contar como distintas categorías idénticas mal codificadas; recupera el texto en español.	`utils.fix_mojibake`, nb 02
Señal de internacionalización por nombre + código de curso	No hay tabla explícita de movilidad; una misma experiencia aparece bajo varios códigos.	`internationalization.py`, nb 03
Exclusión de "intercambio nacional" del foco	No corresponde a internacionalización.	`internationalization.py`
Deduplicación ICFES (mayor puntaje) / CAPP y exámenes (más reciente)	Fuentes con varias filas por estudiante; se requiere un valor por estudiante.	`build_dataset`, nb 02
Foco en pregrado	Mayor volumen de participantes y tasa más alta; mejor cobertura de la señal.	nb 03–05
Descarte de `NIVEL_INGLES`	Cobertura $< 13\,\%$ en pregrado.	nb 03, §4.4
Reorientación a producto descriptivo	Mayor valor accionable y menor riesgo de interpretación/uso indebido que un modelo predictivo.	§7
Dashboard sin servidor sobre cubo agregado	Mantiene la app ligera, permite filtrar por cualquier combinación en el cliente y no expone microdatos (minimización).	`export_dashboard.py`, §8
Discretización fina de variables numéricas (rejilla, no rangos fijos)	Habilita *sliders* de rango con entrada manual manteniendo el cubo acotado y el cross-filtering exacto.	`export_dashboard.py`, `RangeSlider`
Conteo de participantes (no total) junto a cada filtro	El usuario quiere ver dónde se concentra la internacionalización, no el tamaño de cada grupo.	`FilterGroup`, `App.jsx`

Decisión	Justificación	Dónde
Etiquetas de valor y de "Total" siempre visibles en las barras	Legibilidad sin depender del *hover*.	`BarRanking`
Estrato/género solo para equidad	Principio de minimización de datos (Ley 1581 de 2012).	nb 04–05

10. Consideraciones de privacidad

Los datos son anonimizados (identificadores pseudonimizados) y **no se versionan** en el repositorio (excluidos mediante `.gitignore`). Se aplica el principio de minimización: las variables sensibles (estrato, género) se usan únicamente para análisis agregado de equidad y no como insumo obligatorio del modelo, en coherencia con la Ley 1581 de 2012 y su reglamentación [6, 7]. Las visualizaciones del dashboard priorizarán información agregada y evitarán desgloses que permitan identificar estudiantes a partir de grupos muy pequeños.

11. Limitaciones

- La señal de internacionalización es un *proxy* basado en cursos de movilidad registrados en la historia académica. Experiencias no inscritas como asignaturas podrían no quedar capturadas; su validación con la Oficina es un paso pendiente.
- Varias variables tienen faltantes altos en pregrado, lo que limita el análisis de ciertos cruces; en el dashboard, estos casos se agrupan en una categoría "Sin dato" explícita.
- El snapshot `informacion_actual` mezcla cohortes de épocas muy distintas; las tasas globales deben leerse teniendo en cuenta esta heterogeneidad.
- Las asociaciones observadas no implican causalidad.

12. Trabajo pendiente (semanas 10–17)

Con la reorientación a un producto descriptivo (Sección 7), el trabajo restante se concentra en el tablero:

- **Enriquecimiento del tablero:** nuevas vistas (p. ej. mapa de calor facultad × año), más dimensiones de filtrado y exportación de las vistas filtradas a CSV.
- **Validación con usuarios:** evaluación de usabilidad con representantes de la Oficina de Internacionalización, siguiendo principios de visualización orientada a tareas [4, 5],

y ajustes a partir de la retroalimentación.

- **Despliegue y documentación:** publicación del sitio estático, manual de uso y procedimiento de actualización de datos.
- **Validación de la señal:** contrastar la señal de movilidad derivada con los registros administrativos de la Oficina.
- **Preparación del poster** (semana 17).

13. Conclusiones

El trabajo hasta la semana 9 deja un dataset analítico documentado y reproducible, una señal de internacionalización definida y justificada, un informe de calidad de datos y un análisis exploratorio que responde las preguntas PA1–PA6. Los hallazgos son coherentes y defendibles: una tendencia temporal sensible a la pandemia, fuerte heterogeneidad por facultad y programa, un gradiente socioeconómico y asociaciones consistentes con el desempeño académico. Sobre esta base, el proyecto se reorientó hacia un producto descriptivo y se construyó un **dashboard web interactivo** que permite a la Oficina explorar la participación por múltiples dimensiones de forma autónoma. Todo el trabajo es reproducible y su trazabilidad queda consolidada en este informe.

Referencias

[1] R. Wirth and J. Hipp, "CRISP-DM: Towards a Standard Process Model for Data Mining," in *Proc. 4th Int. Conf. Practical Applications of Knowledge Discovery and Data Mining*, 2000.

[2] P. Chapman et al., *CRISP-DM 1.0: Step-by-step Data Mining Guide*. SPSS, 2000.

[3] R. J. A. Little and D. B. Rubin, *Statistical Analysis with Missing Data*, 3rd ed. Wiley, 2019.

[4] B. Shneiderman, "The eyes have it: A task by data type taxonomy for information visualizations," in *Proc. IEEE Symp. Visual Languages*, 1996, pp. 336–343.

[5] T. Munzner, *Visualization Analysis and Design*. CRC Press, 2014.

[6] Congreso de Colombia, "Ley Estatutaria 1581 de 2012," Diario Oficial No. 48.587, 2012.

[7] Ministerio de Comercio, Industria y Turismo, "Decreto 1377 de 2013," Diario Oficial No. 48.834, 2013.