Sistema de analítica y visualización para el análisis de la participación estudiantil en programas de internacionalización de la Universidad de los Andes

Informe técnico de avance — Semana 9

Fase de datos: comprensión del problema, preparación de datos y análisis exploratorio

Juan David Torres Albarracín
Ingeniería de Sistemas y Computación
Universidad de los Andes

2026

Resumen

Este informe documenta el avance del proyecto de grado hasta la semana 9 del cronograma, correspondiente a las fases de *comprensión del problema*, *comprensión y preparación de datos* y *análisis exploratorio* de la metodología CRISP-DM. El objetivo del proyecto es diseñar, desarrollar y evaluar una herramienta de analítica para la Oficina de Internacionalización que permita explorar la participación estudiantil en programas de movilidad. En esta fase se caracterizaron doce fuentes de datos institucionales anonimizadas, se diagnosticó y corrigió un problema de codificación que afectaba a todas las variables de texto, y se construyó un **pipeline reproducible** que integra las fuentes en un conjunto de datos analítico a nivel estudiante (233 987 estudiantes, 44 variables). La contribución metodológica central de esta fase es la **definición de una señal de participación en internacionalización** derivada de los registros académicos, ya que los datos no contienen una tabla explícita de experiencias de movilidad. El análisis exploratorio sobre el subconjunto de pregrado (140 422 estudiantes, tasa de participación del 4,15 %) revela una tendencia temporal con una caída atribuible a la pandemia y recuperación posterior, fuerte heterogeneidad por facultad y programa, un gradiente socioeconómico y asociaciones consistentes entre participación y desempeño académico. El informe cierra formulando la pregunta de modelamiento que se abordará en las fases siguientes, junto con sus salvaguardas metodológicas (manejo de desbalance e prevención de fuga de información).

Índice

1. Introducción y objetivo **3**

2. Comprensión del problema (Semana 4) **3**
2.1. Usuarios y preguntas analíticas 3
2.2. Alcance y criterios de éxito de la fase 4

3. Comprensión y calidad de los datos (Semanas 5–6) **4**
3.1. Inventario de fuentes 4
3.2. Calidad de datos y codificación 5

4. Preparación de datos (Semanas 7–8) **5**
4.1. Definición de la señal de internacionalización 5
4.2. Construcción del dataset analítico 6
4.3. Desbalance de clases 7
4.4. Tratamiento de valores faltantes 7

5. Análisis exploratorio (Semanas 8–9) **7**
5.1. Panorama univariado 7
5.2. PA1 — Evolución temporal 9
5.3. PA3 — Modalidades en el tiempo 9
5.4. PA2 — Participación por facultad y programa 10
5.5. PA4 — Momento de la trayectoria 11
5.6. PA5–PA6 — Perfil académico y diferencias entre grupos 11
5.7. Asociación multivariada 13
5.8. Indicadores principales 13

6. Formulación del problema de modelamiento (PA7) **14**

7. Trazabilidad de decisiones metodológicas **15**

8. Consideraciones de privacidad **16**

9. Limitaciones **16**

10. Trabajo pendiente (semanas 10–17) **16**

11. Conclusiones **17**

1. Introducción y objetivo

El proyecto propone una herramienta de analítica y visualización para que la Oficina de Internacionalización de la Universidad de los Andes pueda explorar la participación estudiantil en programas de movilidad e internacionalización, y disponer de información útil para la toma de decisiones. El desarrollo sigue la metodología CRISP-DM [1, 2] combinada con prácticas iterativas de desarrollo de software.

Este documento es el informe técnico principal del proyecto y recoge, de manera progresiva, el trabajo realizado hasta la **semana 9** del cronograma. Las semanas 4 a 9 corresponden a las tres primeras fases de CRISP-DM:

1. **Comprensión del problema** (semana 4): usuarios, preguntas analíticas, alcance y criterios de éxito.
2. **Comprensión y calidad de datos** (semanas 5–6): inventario de fuentes, diccionario de datos y evaluación de calidad.
3. **Preparación de datos y análisis exploratorio** (semanas 7–9): pipeline de integración, definición de la señal de internacionalización, construcción del dataset analítico y EDA.

El trabajo es reproducible: el código fuente del pipeline está en el paquete `src/`, los análisis en los notebooks `notebooks/01–05`, y las figuras y tablas de este informe se generan automáticamente en `reports/`. La trazabilidad de las decisiones metodológicas se concentra en este documento (Sección 7).

2. Comprensión del problema (Semana 4)

2.1. Usuarios y preguntas analíticas

Se identificaron tres perfiles de usuario: analistas de la Oficina (consulta y reporte de indicadores), coordinación/dirección (planeación y comparación entre unidades) y el equipo técnico de mantenimiento. A partir de la propuesta se priorizaron siete preguntas analíticas (PA):

PA1 Evolución temporal de la participación.

PA2 Participación por facultad y programa académico.

PA3 Modalidades de movilidad más frecuentes.

PA4 Momento de la trayectoria académica en que ocurre la movilidad.

PA5 Características académicas asociadas a la participación.

PA6 Diferencias entre grupos (género, estrato, tipo de admisión).

PA7 Estimación de la probabilidad de participación (modelamiento).

2.2. Alcance y criterios de éxito de la fase

El alcance de la fase de datos comprende: un dataset analítico documentado y reproducible, la definición justificada de la señal de internacionalización, un informe de calidad de datos, un EDA que responda PA1–PA6 y la formulación de la pregunta de modelamiento (PA7). El detalle de requerimientos funcionales y no funcionales se encuentra en `docs/01_requerimientos_semana4.md`.

3. Comprensión y calidad de los datos (Semanas 5–6)

3.1. Inventario de fuentes

Se dispone de doce archivos `parquet` anonimizados. La Tabla 1 resume las fuentes núcleo utilizadas en esta fase, su tamaño y granularidad. Todas identifican al estudiante mediante un código anonimizado; dos fuentes grandes usan el sufijo `_ANOM`, lo que se normaliza en el pipeline.

Cuadro 1: Fuentes núcleo del proyecto y su granularidad.

Fuente	Filas	Variables	Unidad de información
informacion_actual	233 987	73	Estudiante (snapshot, 1 fila/estudiante)
historial_materias	6 958 732	14	Curso–estudiante–periodo
programas	1 770 486	18	Programa–estudiante–periodo
historial_rendimiento	1 230 195	28	Estudiante–periodo
percentiles_historicos	994 875	18	Estudiante–periodo
icfes_saber11	262 148	10	Presentación de examen
grados	139 429	10	Grado obtenido
historial_opciones	173 387	14	Opción–estudiante–periodo
examenes_clasificacion	79 599	8	Clasificación por estudiante
capp_creditos	30 771	7	Cálculo de créditos

Decisión (unidad de análisis). Se adopta el *estudiante* como unidad de análisis y `informacion_actual` (una fila por estudiante) como columna vertebral; las fuentes transaccionales se agregan a nivel estudiante. El diccionario de datos completo se exporta en `reports/tables/diccionario_datos.csv`.

3.2. Calidad de datos y codificación

El perfilamiento (notebook `02`) identificó cuatro problemas de calidad y las decisiones correspondientes:

1. Codificación (*mojibake*). Todas las columnas de texto presentaban caracteres corruptos. Se diagnosticaron **dos esquemas distintos**: en `informacion_actual` el texto UTF-8 fue interpretado con CP437 (p. ej. *Magíster* aparecía como `Mag`+símbolo y *Opción* con un símbolo en lugar de la "ó"); en `historial_materias` fue interpretado con CP850 (p. ej. *DOBLE TITULACIÓN* y *PRÁCTICA* con símbolos de caja en lugar de las vocales acentuadas). Se implementó una corrección automática que detecta el esquema aplicable y recupera el texto en español (*Magíster*, *Opción*, *DOBLE TITULACIÓN*, *PRÁCTICA*). **Esta corrección es imprescindible**: sin ella, categorías idénticas se contarían como distintas.

2. Valores faltantes. Variables socioeconómicas y de ingreso presentan ausencias elevadas, en parte por la heterogeneidad del snapshot (estudiantes antiguos sin ICFES moderno, trayectorias cortas sin rendimiento consolidado). No se descartan a priori; se evalúa su cobertura en el subconjunto de pregrado (Sección 4.4).

3. Múltiples filas por estudiante en ICFES, CAPP y exámenes. Se adopta una regla de deduplicación explícita: para ICFES, el registro de mayor puntaje total; para CAPP y exámenes, el más reciente por fecha.

4. Valores atípicos. El PGA se encuentra dentro del rango esperado $[0, 5]$; los valores bajos (incluidos ceros) corresponden a inicios de trayectoria y se conservan.

El informe de calidad completo está en `reports/tables/informe_calidad_datos.csv`.

4. Preparación de datos (Semanas 7–8)

4.1. Definición de la señal de internacionalización

Las fuentes entregadas **no contienen una tabla explícita de experiencias de internacionalización**. Por lo tanto, la participación debe *derivarse* de los registros académicos. Esta es la decisión metodológica central de la fase de datos.

Criterio adoptado. La Universidad inscribe las experiencias de movilidad como asignaturas en la historia académica del estudiante (`historial_materias`). Se marca un registro como *evento de movilidad* cuando el nombre del curso (corregido de encoding) coincide con un patrón de movilidad — `INTERCAMBIO`, `VIAJE INTERNACIONAL`, `SEMANA`

`INTERNACIONAL`, `DOBLE TITULAC` — o cuando su código pertenece a una lista canónica de cursos de movilidad (p. ej. `DECA-2201`, `INTL-2201`, `MBAE-4543`). Cada evento se clasifica en una *modalidad*.

Justificación. (i) Se usa el nombre del curso *además* del código porque una misma experiencia aparece bajo múltiples códigos de departamento; confiar solo en códigos subestimaría la señal. (ii) Se excluye la modalidad "intercambio nacional" del foco internacional mediante un parámetro explícito. (iii) La señal se construye sin mirar ninguna variable posterior al evento, de modo que pueda reutilizarse como variable objetivo en el modelamiento sin introducir fuga de información. La definición está implementada y es auditable en `src/internationalization.py`.

La Tabla 2 y la Figura 1 resumen la composición de la señal.

Cuadro 2: Composición de la señal de internacionalización por modalidad (eventos).

Modalidad	**Eventos**
Intercambio internacional	7 726
Doble titulación	817
Viaje internacional de estudio	559
Semana internacional	396
Intercambio virtual	28
Total	**9 526**

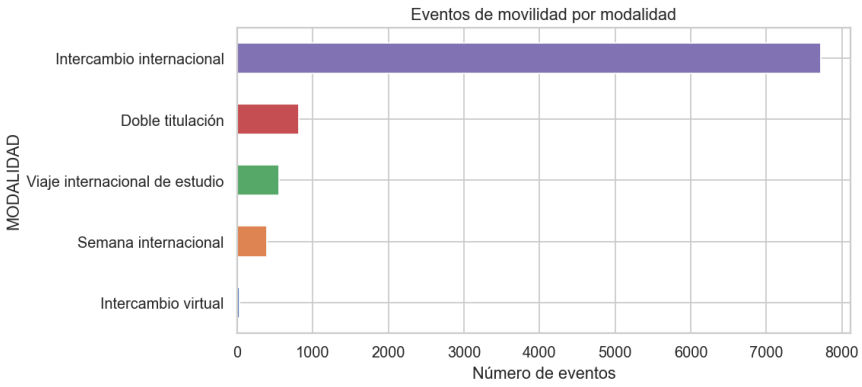


Figura 1: Eventos de movilidad por modalidad. El intercambio internacional concentra cerca del 81 % de los eventos.

4.2. Construcción del dataset analítico

El pipeline (`src/build_dataset.py`, ejecutable con `python -m src.build_dataset`) integra las fuentes mediante uniones por la izquierda sobre la columna vertebral, de modo

que no se pierden estudiantes del universo. Agrega el desempeño académico (PGA histórico y último, créditos, semestres), la posición relativa (percentil de PGA), el avance (semestre), las pruebas de ingreso (ICFES), la clasificación de inglés/matemáticas, el progreso de créditos (CAPP) y la etiqueta `PARTICIPA`. El resultado es un dataset de 233 987 **estudiantes** $\times$ 44 **variables**, validado automáticamente (clave única, conservación del universo, etiqueta binaria).

Prevención de fuga de información. El pipeline conserva, por estudiante, el primer periodo de movilidad (`PRIMER_PERIODO_MOVILIDAD`). En la fase de modelamiento, los predictores de desempeño deberán calcularse en un corte temporal anterior a ese periodo, en coherencia con la advertencia de la propuesta sobre *data leakage*.

4.3. Desbalance de clases

La participación es un fenómeno minoritario: 3,43 % **global** y 4,15 % **en pregrado**. El pregrado concentra el mayor volumen de participantes (5 821) y la tasa más alta entre los niveles con volumen relevante, lo que motiva centrar el análisis y el modelamiento en este nivel.

4.4. Tratamiento de valores faltantes

En el subconjunto de pregrado, la cobertura de las variables candidatas es: `NIVEL_INGLES` $\approx$ 12 % (faltante 87,8 %), bloque de PGA/percentil/avance $\approx$ 45–55 % de faltante, e ICFES $\approx$ 45 % de faltante. Decisiones:

- `NIVEL_INGLES` se **descarta** como variable principal por cobertura insuficiente; se conserva el puntaje de inglés del ICFES.
- Para las variables de desempeño e ICFES se adoptará, en el modelamiento, **imputación por mediana más un indicador de faltante**, evitando descartar estudiantes y haciendo explícito el mecanismo del faltante, en línea con la literatura [8]. No se imputa en el EDA: aquí se analizan los datos observados.

5. Análisis exploratorio (Semanas 8–9)

5.1. Panorama univariado

La Figura 2 muestra la distribución de variables categóricas en pregrado. La población se concentra en pocas facultades grandes (Ingeniería es la de mayor volumen), con género relativamente equilibrado y fuerte presencia de estratos 3–6; una fracción no despreciable tiene estrato ausente. La Figura 3 confirma escalas coherentes: PGA concentrado en 3,8–

4,0, percentil aproximadamente uniforme e ICFES aproximadamente simétrico alrededor de ~ 355.

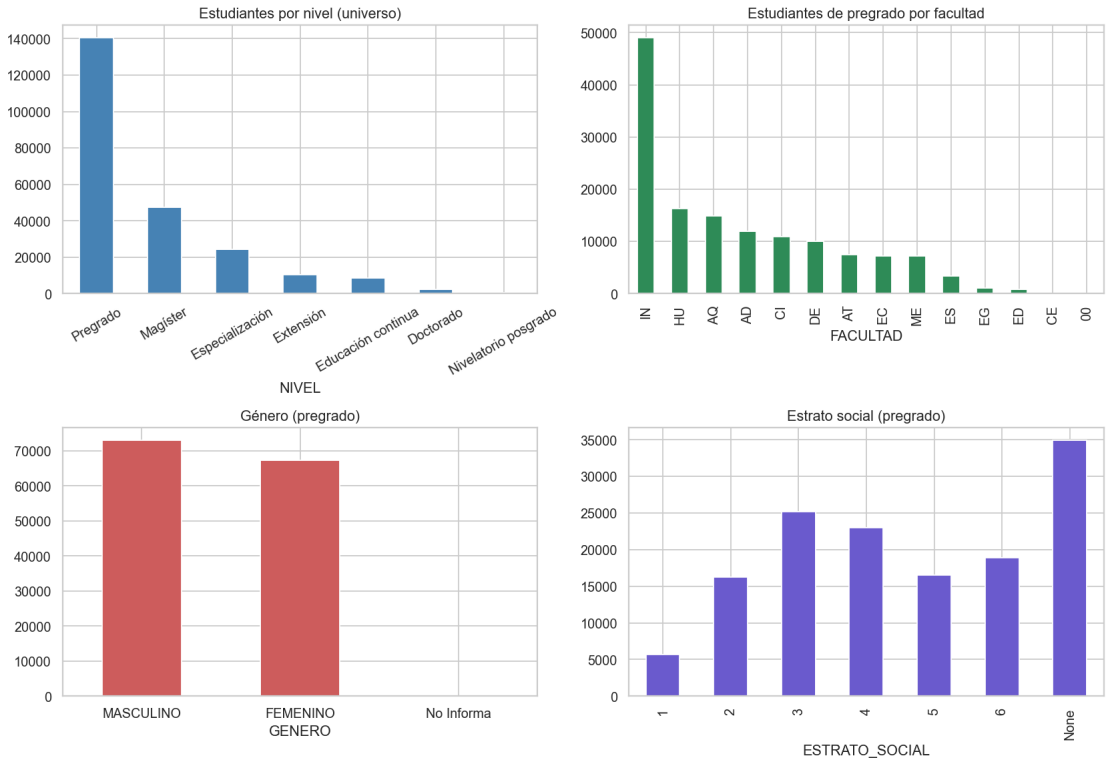


Figura 2: Distribuciones univariadas de variables categóricas (pregrado).

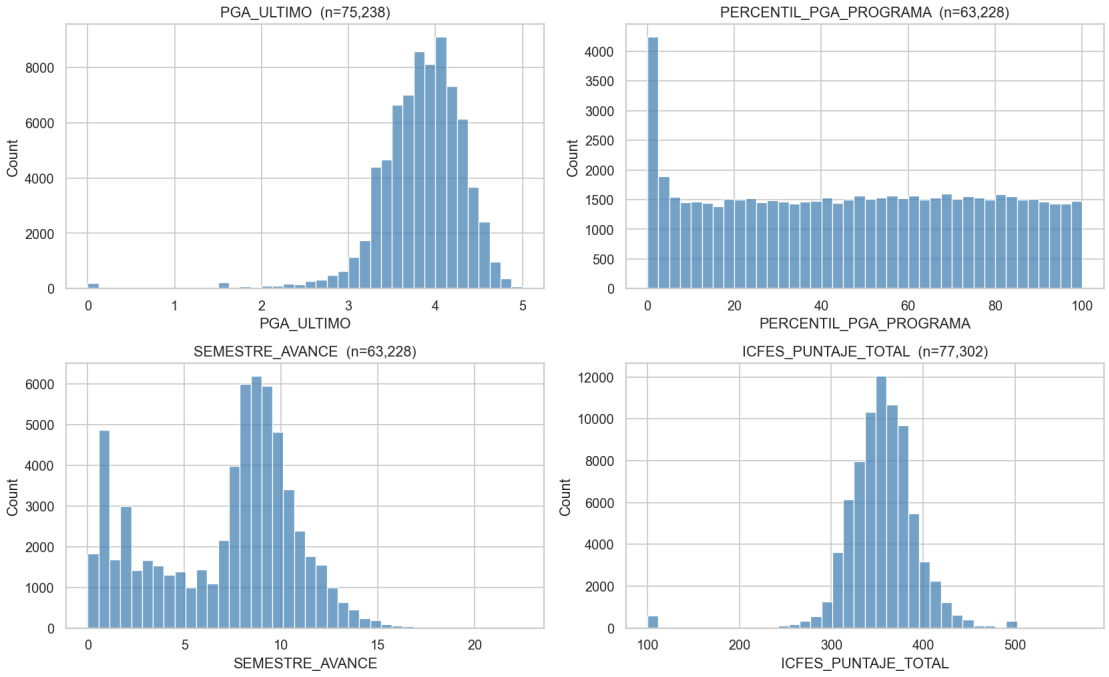


Figura 3: Distribuciones univariadas de variables numéricas de desempeño e ingreso (pregrado).

5.2. PA1 — Evolución temporal

La Figura 4 muestra una tendencia creciente de la movilidad hasta estabilizarse en $\sim$ 400–450 eventos anuales en la década de 2010, una **caída pronunciada en 2020–2021** (447 eventos en 2019 frente a 257 y 268 en 2020 y 2021) atribuible a las restricciones de la pandemia de COVID-19, y una **recuperación fuerte desde 2022** que alcanza máximos históricos ($\sim$ 585–595 eventos en 2023–2025). Que la señal reaccione a un choque externo conocido de la forma esperada es también una validación indirecta de su correcta construcción.

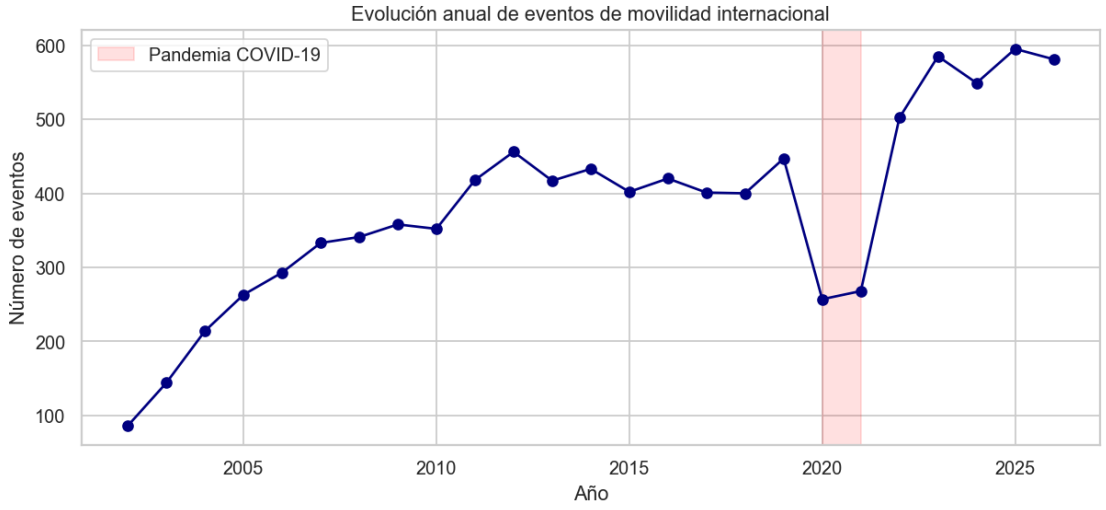


Figura 4: Evolución anual de eventos de movilidad internacional. La franja roja señala el periodo de pandemia.

5.3. PA3 — Modalidades en el tiempo

La Figura 5 muestra que el intercambio internacional domina en todo el periodo, con contribuciones menores pero estables de doble titulación, viajes y semanas internacionales. El intercambio virtual aparece puntualmente alrededor de 2020–2021, coherente con la sustitución de la movilidad física durante la pandemia.

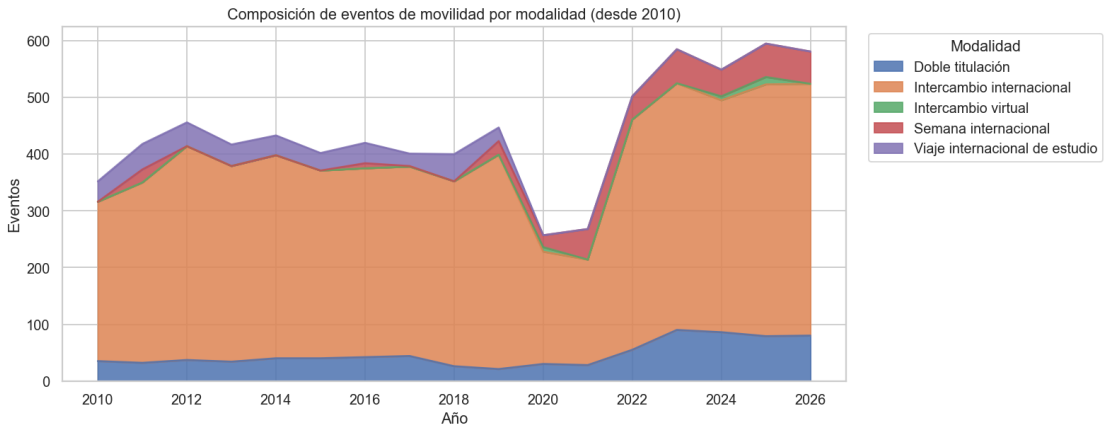


Figura 5: Composición de eventos de movilidad por modalidad desde 2010.

5.4. PA2 — Participación por facultad y programa

La participación es muy heterogénea entre unidades académicas (Figura 6): la tasa va desde $\sim 0{,}1\,\%$ hasta $\sim 12{,}3\,\%$ (Administración presenta la tasa más alta; Arquitectura, Economía y Derecho también destacan). A nivel de programa (Figura 7) la heterogeneidad es aún mayor. La facultad/programa es, por tanto, una variable estructural clave y una dimensión de segmentación prioritaria para el dashboard.



Figura 6: Tasa de participación por facultad (pregrado).

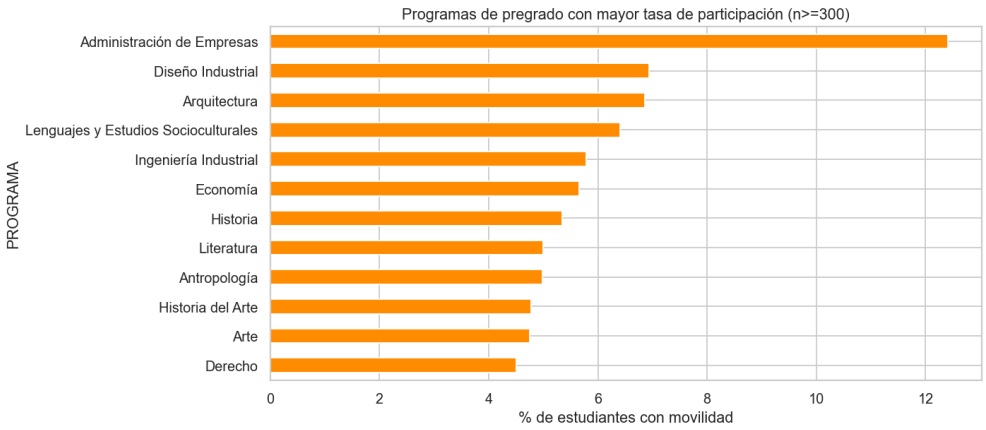


Figura 7: Programas de pregrado con mayor tasa de participación ($n \geq 300$).

5.5. PA4 — Momento de la trayectoria

Los participantes se concentran en etapas intermedias y avanzadas de la carrera (Figura 8): su avance mediano es de $\sim 8{,}75$ semestres frente a ~ 8 en no participantes, con una distribución mucho más estrecha. Esto tiene una implicación directa sobre el modelamiento: los predictores de desempeño deben "congelarse" en un corte anterior al primer evento, no al final de la trayectoria.

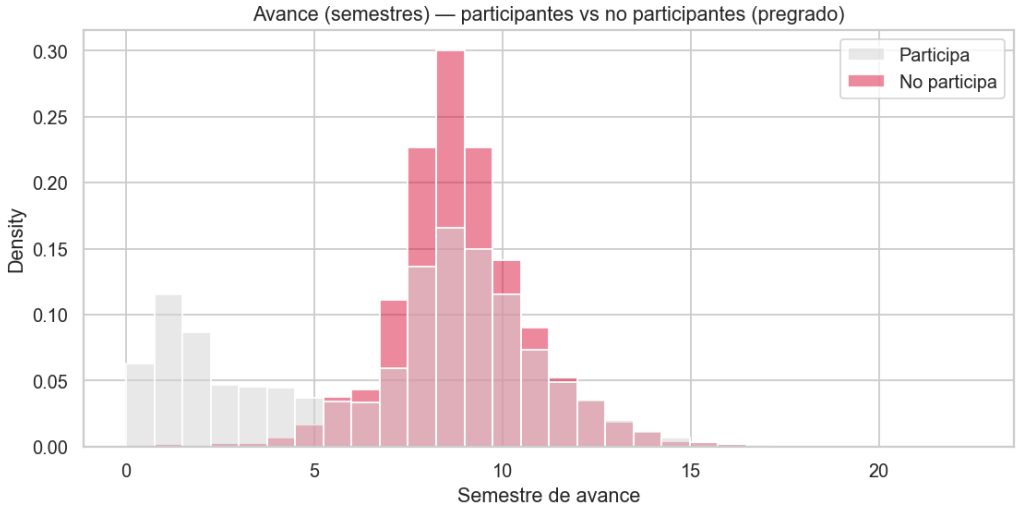


Figura 8: Avance en semestres: participantes frente a no participantes (pregrado).

5.6. PA5–PA6 — Perfil académico y diferencias entre grupos

Los participantes muestran, en promedio, mejor desempeño y mejor perfil de ingreso (Figura 9, Tabla 3). Existe además un **gradiente socioeconómico** claro (Tabla 4): la tasa de participación crece de forma monótona con el estrato (de $\sim 0{,}4\,\%$ en estratos 1–2 a $\sim 9{,}5\,\%$ en estrato 6) y es algo mayor en mujeres. Estos resultados deben interpretarse como **asociaciones, no causas**, y comunicarse como análisis de equidad.

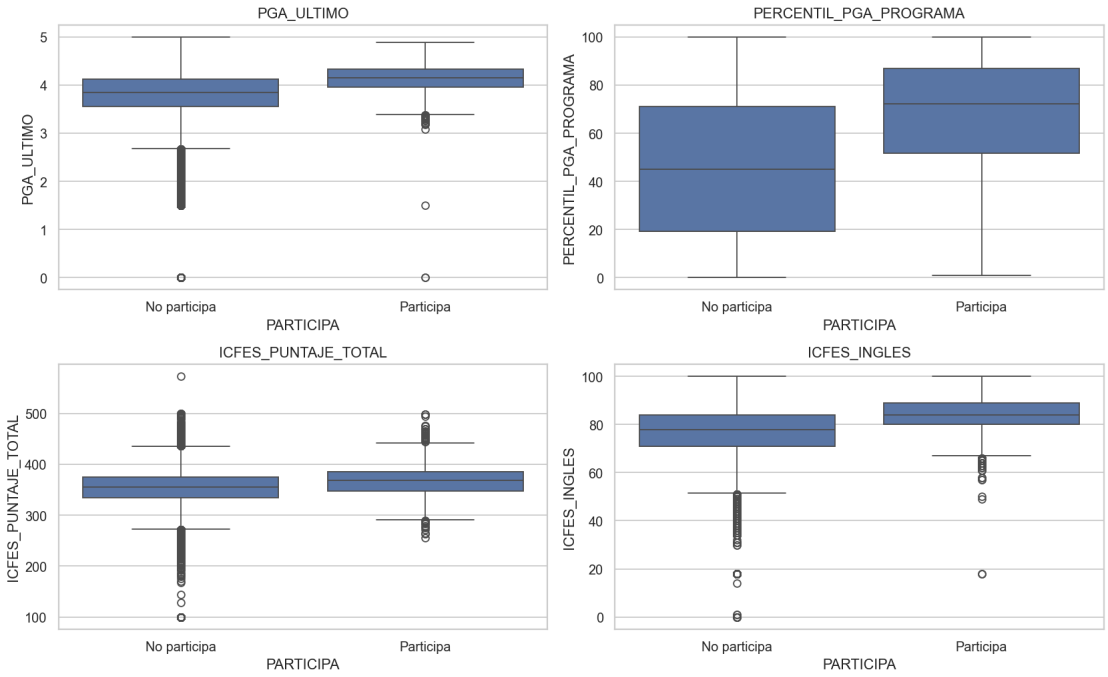


Figura 9: Comparación del desempeño y perfil de ingreso entre participantes y no participantes (pregrado).

Cuadro 3: Perfil promedio de participantes y no participantes (pregrado).

Variable	**No participa**	**Participa**	**Diferencia**
PGA (último)	3,81	4,14	+0,33
Percentil PGA (programa)	45,8	67,7	+21,9
Semestre de avance	6,93	8,87	+1,95
ICFES total	354,3	368,4	+14,1
ICFES inglés	77,4	84,6	+7,2
% créditos aprobados	0,86	0,94	+0,09

Cuadro 4: Tasa de participación por grupo (pregrado).

Estrato social		**Género**	
Estrato	**Tasa (%)**	**Género**	**Tasa (%)**
6	9,48	Femenino	4,65
5	6,26	Masculino	3,68
4	3,33		
3	0,94		
2	0,43		
1	0,42		

5.7. Asociación multivariada

La Figura 10 presenta las correlaciones entre variables numéricas y la participación. Individualmente, las correlaciones con `PARTICIPA` son de magnitud baja a moderada (lo esperable para un evento poco frecuente), pero con signos coherentes: el percentil de PGA por programa y el PGA muestran la asociación positiva más clara, seguidos del avance y el perfil de ingreso. Ninguna variable domina por sí sola, lo que anticipa que un modelo multivariado — y posiblemente no lineal — capturará mejor el fenómeno que cualquier regla univariada. La correlación entre predictores (p. ej. PGA y percentil) alerta sobre colinealidad a considerar en modelos lineales.

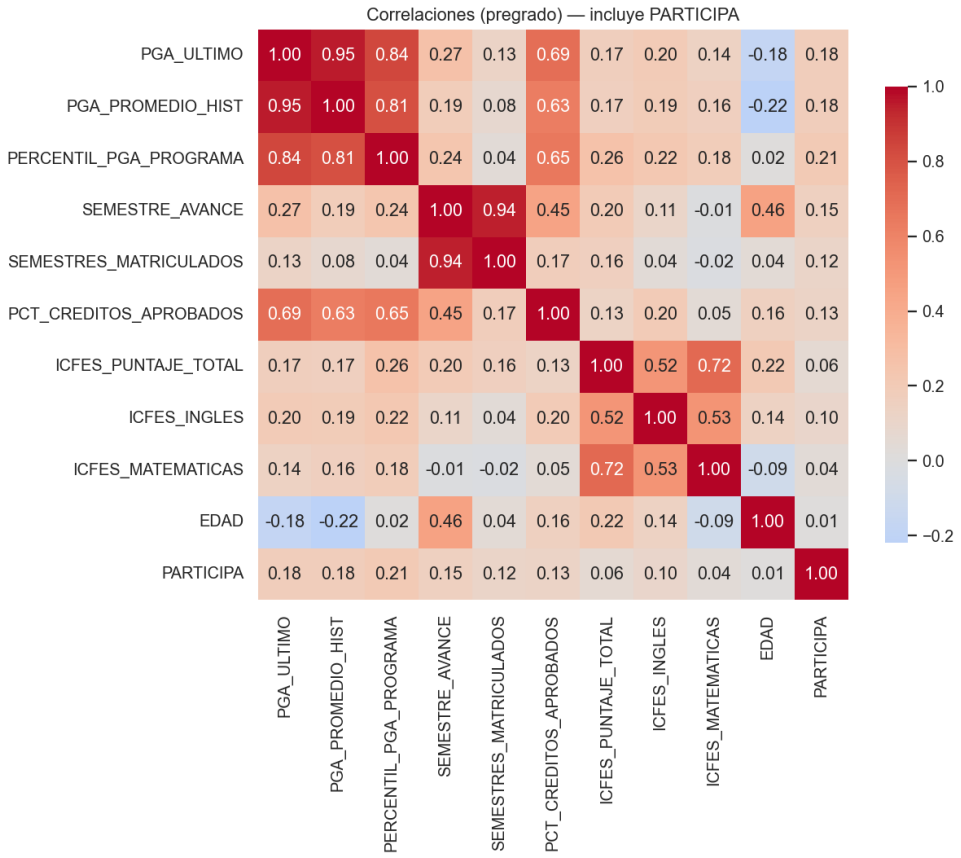


Figura 10: Matriz de correlaciones de variables numéricas (pregrado), incluyendo la etiqueta de participación.

5.8. Indicadores principales

La Tabla 5 consolida los indicadores que alimentarán el módulo de resumen del dashboard (exportados en `reports/tables/indicadores_principales.csv`).

Cuadro 5: Indicadores principales de la fase de datos.

Indicador	**Valor**
Estudiantes (universo)	233 987
Estudiantes de pregrado	140 422
Participantes (total)	8 036
Participantes (pregrado)	5 821
Tasa de participación global	3,43 %
Tasa de participación en pregrado	4,15 %
Eventos de movilidad	9 526
Año pico de eventos	2025
Modalidad principal	Intercambio internacional
Facultad con mayor tasa	Administración
Avance mediano de participantes	8,75 semestres

6. Formulación del problema de modelamiento (PA7)

A partir del análisis se formaliza el problema que se abordará desde la semana 10:

> *Dado un estudiante de pregrado, estimar la probabilidad de que participe en una experiencia de internacionalización en algún momento de su carrera, usando únicamente información disponible antes del evento.*

Justificación. Existe una variable objetivo bien definida y auditable (`PARTICIPA`) con una tasa de base realista; el EDA mostró asociaciones consistentes que dan sustento a un modelo con capacidad discriminante; y el problema es relevante para la Oficina, pues permite identificar perfiles con baja participación y focalizar estrategias.

Salvaguardas metodológicas heredadas al modelamiento.

1. *Desbalance de clases*: la exactitud no basta (un clasificador trivial acertaría $\sim 96\,\%$); se usarán precisión, *recall*, F1 y PR-AUC, además de ROC-AUC, y se evaluarán técnicas de manejo de desbalance [12].
2. *Prevención de fuga de información*: los predictores se calcularán en un corte temporal anterior al primer evento de movilidad.
3. *Complejidad progresiva*: línea base trivial, regresión logística [3], árboles/Random Forest [4], boosting [5], con interpretabilidad mediante SHAP [6] y validación cruzada [11]. Las implementaciones se apoyarán en *scikit-learn* [7].
4. *Variables descartadas* por cobertura: `NIVEL_INGLES`.

7. Trazabilidad de decisiones metodológicas

La Tabla 6 consolida las decisiones relevantes de la fase, su justificación y su ubicación en el repositorio.

Cuadro 6: Trazabilidad de decisiones metodológicas (semanas 4–9).

Decisión	**Justificación**	**Dónde**
Unidad de análisis = estudiante	`informacion_actual` tiene 1 fila/estudiante; permite integrar el resto por agregación.	nb 01, `build_dataset`
Corrección automática de dos esquemas de *mojibake*	Evita contar como distintas categorías idénticas mal codificadas; recupera el texto en español.	`utils.fix_mojibake`, nb 02
Señal de internacionalización por nombre + código de curso	No hay tabla explícita de movilidad; una misma experiencia aparece bajo varios códigos.	`internationalization.py`, nb 03
Exclusión de "intercambio nacional" del foco	No corresponde a internacionalización.	`internationalization.py`
Deduplicación ICFES (mayor puntaje) / CAPP y exámenes (más reciente)	Fuentes con varias filas por estudiante; se requiere un valor por estudiante.	`build_dataset`, nb 02
Foco en pregrado	Mayor volumen de participantes y tasa más alta; mejor cobertura de la señal.	nb 03–05
Descarte de `NIVEL_INGLES`	Cobertura $< 13\,\%$ en pregrado.	nb 03, §4.4
Imputación por mediana + indicador de faltante (en modelamiento)	Evita descartar estudiantes y hace explícito el faltante [8].	§4.4
Conservar `PRIMER_PERIODO_MOVILIDAD`	Habilita la construcción de predictores anti-*leakage*.	`build_dataset`, nb 03
Métricas sensibles al desbalance	Tasa de participación $\sim 4\,\%$; la exactitud es engañosa [12].	§ PA7

Decisión	Justificación	Dónde
Estrato/género solo para equidad	Principio de minimización de datos (Ley 1581 de 2012).	nb 04–05

8. Consideraciones de privacidad

Los datos son anonimizados (identificadores pseudonimizados) y **no se versionan** en el repositorio (excluidos mediante `.gitignore`). Se aplica el principio de minimización: las variables sensibles (estrato, género) se usan únicamente para análisis agregado de equidad y no como insumo obligatorio del modelo, en coherencia con la Ley 1581 de 2012 y su reglamentación [13, 14]. Las visualizaciones del dashboard priorizarán información agregada y evitarán desgloses que permitan identificar estudiantes a partir de grupos muy pequeños.

9. Limitaciones

- La señal de internacionalización es un *proxy* basado en cursos de movilidad registrados en la historia académica. Experiencias no inscritas como asignaturas podrían no quedar capturadas; su validación con la Oficina es un paso pendiente.
- Varias variables tienen faltantes altos en pregrado, lo que limita el análisis de ciertos cruces y condiciona la estrategia de imputación del modelamiento.
- El snapshot `informacion_actual` mezcla cohortes de épocas muy distintas; las tasas globales deben leerse teniendo en cuenta esta heterogeneidad.
- Las asociaciones observadas no implican causalidad.

10. Trabajo pendiente (semanas 10–17)

- **Semanas 10–12 (modelamiento):** construcción de predictores anti-*leakage*, línea base y regresión logística, modelos de árboles y ensamble, validación cruzada e interpretabilidad (SHAP).
- **Semana 13 (diseño del sistema):** arquitectura, módulos y prototipos de la interfaz.
- **Semana 14 (dashboard):** implementación de la interfaz, filtros, indicadores e integración del modelo.
- **Semanas 15–16 (validación y cierre):** pruebas, evaluación con usuarios, documentación técnica y preparación del poster.

11. Conclusiones

El trabajo hasta la semana 9 deja un dataset analítico documentado y reproducible, una señal de internacionalización definida y justificada, un informe de calidad de datos y un análisis exploratorio que responde las preguntas PA1–PA6. Los hallazgos son coherentes y defendibles: una tendencia temporal sensible a la pandemia, fuerte heterogeneidad por facultad y programa, un gradiente socioeconómico y asociaciones consistentes con el desempeño académico. Sobre esta base se formuló la pregunta de modelamiento (PA7) con sus salvaguardas, dejando el proyecto en condiciones de iniciar la fase predictiva. Todo el trabajo es reproducible y su trazabilidad queda consolidada en este informe.

Referencias

[1] R. Wirth and J. Hipp, "CRISP-DM: Towards a Standard Process Model for Data Mining," in *Proc. 4th Int. Conf. Practical Applications of Knowledge Discovery and Data Mining*, 2000.

[2] P. Chapman et al., *CRISP-DM 1.0: Step-by-step Data Mining Guide*. SPSS, 2000.

[3] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. Springer, 2009.

[4] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.

[5] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD*, 2016, pp. 785–794.

[6] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems 30*, 2017, pp. 4765–4774.

[7] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[8] R. J. A. Little and D. B. Rubin, *Statistical Analysis with Missing Data*, 3rd ed. Wiley, 2019.

[9] B. Shneiderman, "The eyes have it: A task by data type taxonomy for information visualizations," in *Proc. IEEE Symp. Visual Languages*, 1996, pp. 336–343.

[10] T. Munzner, *Visualization Analysis and Design*. CRC Press, 2014.

[11] R. Kohavi, "A study of cross-validation and bootstrap for accuracy estimation and model selection," in *Proc. 14th IJCAI*, 1995, pp. 1137–1145.

[12] T. Saito and M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," *PLoS ONE*, vol. 10, no. 3, e0118432, 2015.

[13] Congreso de Colombia, "Ley Estatutaria 1581 de 2012," Diario Oficial No. 48.587, 2012.

[14] Ministerio de Comercio, Industria y Turismo, "Decreto 1377 de 2013," Diario Oficial No. 48.834, 2013.